



Univerzitet u Beogradu - Elektrotehnički fakultet

Katedra za signale i sisteme



## **DIPLOMSKI RAD**

# **Prepoznavanje emocija primenom elektroencefalografije i metoda obučavanja sa nadgledanjem**

**Kandidat**

Ana Đukić, 2015/0130

**Mentor**

dr Milica Janković, docent

Beograd, *septembar* 2019. godine

## REZIME RADA

U ovom radu je predstavljena izvršena analiza nad elektroencefalografskim (EEG) podacima s ciljem da se postigne rekognicija emocionalnih stanja koja odgovara samoocenama ispitanika čiji su EEG signali snimani.

Korišćena je javno dostupna baza podataka DEAP. Ova baza je rezultat ekperimenta iz 2011. godine u kome su ispitanicima mereni elektrofiziološki signali, među kojima je EEG, dok su gledali isečke muzičkih video snimaka. Ekperiment je sproveden s namerom da se konstruiše inteligentni sistem za preporuku pesama.

Nakon učitavanja i ispitivanja podataka, izvršena je analiza u frekvencijskom domenu. Procenjena je spektralna gustina snage kao parametar koji nosi korisnu informaciju i koji je izabran da bude ulaz u klasifikatore. Za obeležja su uzete sume spektralne gustine snage na opsezima frekvencija koji odgovaraju teta, alfa, beta i gama talasima elektroencefalografskog signala.

Testirana su dva klasifikatora: K najbližih suseda (eng. *K nearest neighbors*, KNN) i metoda nosećih vektora (eng. *support-vector machine*, SVM). Razlog za ovo poređenje je u tome što se za KNN klasifikator smatra da je robustan nad zašumljenim podacima i da daje dobre rezultate nad velikim brojem vektora atributa. SVM klasifikator se u praksi pokazuje pogodan u slučaju da klase nisu linearno separabilne, i kada se klasifikacija sprovodi u višedimenzionalnim prostorima.

Rezultat u ovom radu su modeli klasifikacije utrenirani nad delom skupa ulaznih podataka i odgovarajućim referentnim labelama koje su binarno proračunate na osnovu samoocena ispitanika za četiri dimenzije emocionalnog doživljaja. Prikazane su proračunate tačnosti klasifikacije i matrice kofuzije.

## ZAHVALNICA

*Srdačno zahvaljujem svojoj mentorki docentu Milici Janković na podršci tokom studiranja, strpljenju i pomoći pri izradi ovog diplomskog rada.*

*Zahvaljujem profesoru Predragu Tadiću na razumevanju i savetima.*

*Zahvaljujem kolegama Borisu Milićeviću i Daliboru Veljkoviću na posvećenoj pažnji i pomoći tokom analize rezultata u ovom radu.*

*Zahvaljujem porodici koja je uvek uz mene.*

*Hvala vam.*

## SADRŽAJ

REZIME RADA .....	2
ZAHVALNICA .....	3
SADRŽAJ .....	4
1 UVOD .....	5
2 METODOLOGIJA RADA .....	7
2.1 DEAP baza podataka .....	7
2.2 Elektroencefalografija .....	8
2.3 Izdvajanje obeležja .....	9
2.4 Metode klasifikacije .....	11
3 REZULTATI .....	13
4 DISKUSIJA .....	20
5 ZAKLJUČAK .....	21
6 LITERATURA .....	22

## 1 UVOD

Emocije predstavljaju psihološko-fiziološki proces koji je posledica situacije u kojoj se osoba nalazi ili stresora kom je osoba izložena. Emocionalno stanje je korelisano sa raspoloženjem, motivacijama, često i donošenjem odluka. Ispoljavanje emocija ima značajnu ulogu u međuljudskoj komunikaciji, i može se sprovesti preko facijalnih ekspresija, kroz govor, gestikulaciju, putem intonacije glasa. Ovo ukazuje da su emocije važan faktor i indikator psihičkog stanja čoveka.

Tumačenje emocija igra važnu ulogu u oblasti medicine. Pravilno prepoznavanje i razumevanje emotivnog stanja čoveka može biti od velike koristi i može znatno unaprediti dijagnostiku. Osim u medicini i rehabilitaciji, tumačenje emocija može biti korisno stručnjacima iz drugih sfera rada i istraživanja, kao što su marketing, razvijanje video igara, filmska industrija. Rekognicija emocija bi mogla da postane mogućnost pametnih telefona, pametnih automobila i drugih uređaja sa kojima ljudi svakodnevno interaguju.

Zbog kompleksnosti i značaja, prepoznavanje emocionalnog stanja je atraktivno stručnjacima različitih naučnih disciplina. Danas se ove analize vrše nad raznim podacima, kao što su fotografije, video snimci, zatim elektrofiziološki signali kao EEG, EKG, respiratorni ritam. Klasifikacija se najčešće vrši pomoću neuralnih mreža ili pomoću modela mašinskog učenja, kao što su: metod nosećih vektora, K najbližih suseda, linearna diskriminantna analiza (LDA) i drugi, što zavisi od ulaznih podataka u klasifikator.

Jedan pristup interpersonalnoj klasifikaciji emocija jeste detekcija na osnovu audio-vizuelnog sadržaja. Kamerom se snimaju facijalne ekspresije ispitanika dok su u određenim afektivnim stanjima. Ovakve studije tipično imaju visoku tačnost prepoznavanja emocija, međutim mana im je što se oslanjaju na facijalne ekspresije koje nisu nužno pravi pokazatelj stvarnog emotivnog stanja ispitanika, jer su ljudi u stanju da svojevolejno kontrolišu izraz lica.

Drugi pristup predstavlja detekcija emocija na osnovu elektrofizioloških signala, kao što su: električna aktivnost srca, električna aktivnost mišića određenih delova tela, električna aktivnost kore velikog mozga, električna provodljivost kože, aktivnost respiratornog sistema. Ovi signali su dobri pokazatelji stvarnog emotivnog stanja ljudi, ali javlja se problem prikupljanja kvalitetnih baza podataka, usled poteškoća prilikom izazivanja ciljanih emocija kod ljudi.

U tabeli 1 prikazan je pregled istraživanja nekih autora u oblasti interpersonalne klasifikacije emocija. Dati su polazni skupovi podataka, korišćene metode, i postignuti rezultati. Može se primetiti pomenuta visoka tačnost klasifikacije na osnovu facijalnih ekspresija. Govor je, kao i izrazi lica, pod voljnom kontrolom čoveka, te klasifikacija na osnovu

govornog signala ima iste prednosti i mane kao klasifikacija na osnovu facijalnih ekspresija. Prepoznavanje emocija na osnovu elektrofizioloških signala je manje uspešno u poređenju sa prethodnim pristupima. Tačnost ovih klasifikatora je bolja što je sadržaj kojim se vrši izazivanje emocija više stimulišuće, a to bi se moglo reći za muzičke i video sadržaje, u poređenju sa slikama.

Tabela 1 Pregled stanja u oblasti interpersonalnog prepoznavanja emocija

Istraživači	Broj emocija	Ulaz klasifikatora	Način prikupljanja podataka	Klasifikator	Tačnost
Husam Salih i drugi [1]	6	Obeležja slike ljudskog lica	BU-4DFE baza slika	SVM	95 %
A. Sonawane i drugi [2]	6	Obeležja govornog signala	MFCC baza podataka	SVM	90 %
J.Kim i drugi [3]	4	Elektrofiziološki signali (EKG, EMG, GSR, respiracija)	Eksperiment u kom je izazivanje emocija vršeno pomoću muzičkog sadržaja	pLDA	70 %
Wei-Long Zheng i drugi [4]	3	Elektrofiziološki signali (EEG)	Eksperiment u kom je izazivanje emocija vršeno pomoću video i audio sadržaja	GELM sa DE obeležjima <sup>1</sup>	69 %
R.M. Mehmood i drugi [5]	4	Elektrofiziološki signali (EEG)	IAPS baza slika	SVM, KNN	61 %

Cilj ovog rada je da se prikaže potencijalna uspešnost interpersonalne procene osnovnih emocionalnih doživljaja na osnovu izabranih obeležja iz elektroencefalografskog signala, u prisustvu reference koju predstavljaju samoocene ispitanika čija su EEG merenja zabeležena.

U drugom poglavlju ovog rada predstavljena je baza podataka koja je analizirana kroz opise izvođenja eksperimenta, način odabiranja muzičkih video snimaka, opis ciljnih emocionalnih doživljaja i način samoocene ispitanika. Zatim je predstavljena elektroencefalografija, ukazano je na odabir obeležja i metode klasifikacije. U trećem poglavlju su analizirani potpun i redukovani skup obeležja i prikazane su performanse klasifikatora. Na kraju su izloženi zaključci izvedeni nakon sprovedene interpersonalne klasifikacije.

<sup>1</sup> Model *discriminative graph regularized extreme learning machine* (GELM) koji koristi diferencijalnu entropiju (DE) kao obeležja

## 2 METODOLOGIJA RADA

U ovom poglavlju predstavljena je baza podataka koja je korišćena, a zatim su opisani signali koji su analizirani, izdvojena obeležja i način klasifikacije. Obrada podataka je izvršena u programskom jeziku *Python*, detaljniji opis i više informacija na: <https://www.python.org/>.

### 2.1 DEAP baza podataka

DEAP (eng. *a Database for Emotion Analysis using Physiological signals*) je javno dostupan multimodalan skup podataka snimljen za analizu afektivnih stanja ljudi. Ovaj skup je predstavljen u radu [6].

Bazu čine elektroencefalografski signali, periferni fiziološki signali, i video snimci facijalnih ekspresija za 32 zdrava ispitanika dok su gledali 40 isečaka različitih muzičkih video klipova. Na slici 1 je prikazana postavka mernih elektroda i okruženja eksperimenta.



Slika 1 Ispitanik neposredno pred merenje, preuzeto iz [1]

Video snimci su izabrani kroz nekoliko koraka. Na osnovu emocionalnih ključnih reči izdvojeno je približno hiljadu pesama. Zatim je definisan prostor *valence-arousal* koji je podeljen u 4 kvadranta koji su odgovarajući za kombinacije niskih i visokih vrednosti valence i pobuđenosti. Pesme su birane tako da je obezbeđena raznovrsnost kroz kvadrante, da postoji dostupan propratni video snimak, da dovoljno dobro reflektuju emocionalni sadržaj i da su

primerene za eksperiment. Cilj je bio da se selektuju muzički klipovi koji indukuju što jasniju emocionalnu reakciju.

Odgovarajući isečci u trajanju od 60 sekundi su izdvojeni na osnovu raznih proračunatih parametara, među kojima su glasnoća, vizuelna pokretnost i uzбудljivost, varijacija boja i osvetljenja. Ispitanici su ocenjivali video snimke na skali od 1 do 9 prema sledećim dimenzijama emocionalnog doživljaja:

- Pobuđenost (eng. *arousal*) predstavlja meru aktivnosti organizma. Može varirati između stanja niske aktivnosti što je karakteristično za dosadu, nezainteresovanost, i stanja visoke aktivnosti što opisuje uzbuđenost ili napetost.
- Valenca (eng. *valence*) predstavlja meru prijetnosti događaja ili situacije i kreće se od stanja neprijatnosti, koje opisuje tugu, stres, do stanja prijetnosti koje odgovara osećaju sreće ili ushićenosti.
- Dominantnost (eng. *dominance*) se vezuje za kontrolu koju čovek ima nad situacijom u kojoj se nalazi, i varira između stanja niske dominantnosti (bez kontrole nad situacijom) i stanja velike dominantnosti (potpuna kontrola).
- Dopadanje (eng. *liking*) opisuje u kojoj meri se ispitaniku svidja sadržaj.

Za potrebe ovog rada preuzeti su preprocesirani podaci za Python okruženje koji se mogu pronaći na sajtu: <https://www.eecs.qmul.ac.uk/mmv/datasets/deap/index.html>. Preuzeta datoteka sadrži dve tablične strukture od kojih je jedna matrica snimljenih podataka za sve ispitanike tokom svakog pojedinačnog video klipa sa 40 kanala merenja, a druga je matrica ocena koje su ispitanici dodelili video klipovima. Dodatne informacije o bazi i merenjima su dostupne u radu [6].


## 2.2 Elektroencefalografija

Elektroencefalografija (EEG) predstavlja elektrofiziološku metodu snimanja električne aktivnosti kore velikog mozga. To se postiže postavljanjem elektroda na površinu glave, a beleži se razlika potencijala između svake merne elektrode i jedne standardne referentne elektrode. Snimljeni EEG signal ima amplitudu u opsegu od nekoliko mikrovolti do nekoliko milivolti. Komponente EEG signala nalaze se u frekvencijskom opsegu 1-50 Hz.

EEG signal koji potiče od spontane aktivnosti pri mirovanju je promenljiv i neregularan i svrstava se u kontinualne stohastičke signale. Istovremeno postoje i karakteristični ritmovi u signalu koji su uslovljeni kortikalnom aktivnošću i oni se mogu koristiti za proučavanje emocionalnog stanja ispitanika [7].

U karakteristične ritmove EEG signala spadaju: delta (do 4 Hz), teta (4-7 Hz), alfa (7-13 Hz), beta (13-30 Hz) i gama talasi (iznad 30 Hz). Na slici 2 je dat prikaz primera ovih ritmova.






Slika 2 Karakteristični talasi EEG signala, preuzeto sa <https://en.wikipedia.org/wiki/Electroencephalography> i pristupljeno septembra 2019.


## 2.3 Izdvajanje obeležja

Matrica merenih podataka sadrži snimljenih 40 kanala tokom merenja za svakog ispitanika, za sve video klipove. Oдавde je izdvojeno prvih 32 kanala koji predstavljaju EEG signale. Na slici 3 je dat prikaz ovih signala u vremenskom domenu.



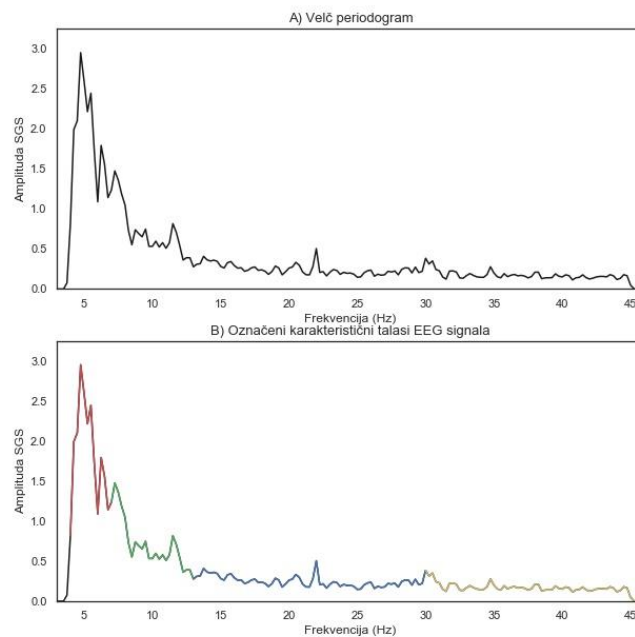
Slika 3 Primeri EEG signala u vremenskom domenu (nasumično izabrani iz skupa podataka)

Predstava signala u frekvencijskom domenu pruža intuitivniji uvid u svojstva i kvalitativno ponašanje signala. Signali su konvertovani iz vremenskog u frekvencijski domen Furijeovom transformacijom (slika 4). Ova transformacija pretvara informacije o signalu u magnitudu i faznu komponentu svake frekvencije [8].



Slika 4 EEG signal u A) vremenskom domenu i B) njegova amplitudska karakteristika u frekvencijskom spektru

Za dalju analizu potrebno je izdvojiti obeležja kao mere karakterističnosti signala, koja bi se prosleđivala klasifikatorima kao korisna informacija za prepoznavanje emocionalnih stanja. U tu svrhu birani su karakteristični ritmovi EEG signala, kako je sugerisano u radu [9]. Odabrano je da obeležja budu sume vrednosti procenjene spektralne gustine snage na odgovarajućim frekvencijskim opsezima. Spektralna gustina snage (SGS) je procenjena pomoću Velč metode, sa prozorom od 4 sekunde (slika 5). Korišćena je funkcija `scipy.signal.welch` iz *Python* biblioteke *scipy*. Konačna obeležja su sume procenjene SGS teta, alfa, beta i gama talasa, kao i količnik suma SGS beta i alfa talasa za svaki kanal EEG merenja.



Slika 5 A) Spektralna gustina snage signala i B) označeni teta (crvena boja), alfa (zeleno), beta (plavo) i gama (žuto) opsezi

## 2.4 Metode klasifikacije

Metode klasifikacije na osnovu labeliranih podataka formiraju modele predikcije koji opisuju zavisnost izlaznih labela u odnosu na ulazna obeležja. Ove metode podrazumevaju supervizijsko učenje, tj. formiranje modela u prisustvu reference [10].

Ulazna obeležja predstavljaju niz deskriptora koji treba da na što bolji način karakterišu uzorak koji treba da se prepozna. Ulazna obeležja za potrebe analize u ovom radu su opisana u poglavlju 2.3.

Izgradnja klasifikatora podrazumeva dve faze: treniranje klasifikacionog modela i njegovo testiranje. Treniranjem se formira klasifikaciona funkcija na osnovu jednog dela podataka. U fazi testiranja, kroz klasifikator se propuštaju test podaci, odnosno podaci koji nisu bili poznati u fazi treninga. Na ovaj način se simulira namena klasifikatora, što je klasifikacija budućih, trenutno nepoznatih podataka.

Reference, ili izlazne labele, predstavljaju set podataka koji nosi informaciju o tačnoj klasi kojoj neki uzorak pripada. Reference su kreirane na osnovu samoocena ispitanika za četiri dimenzije emocionalnog doživljaja: valencu, pobuđenost, dominantnost i dopadanje, koje su opisane u poglavlju 2.1. Postavljen je binaran prag na 4.5, što je polovina skale. Sve ocene koje su iznad 4.5 dobijaju labelu 1, a sve ocene koje su ispod dobijaju labelu 0.

Testirana su dva klasifikatora, K najbližih suseda i metoda nosećih vektora.

K najbližih suseda (eng. *K nearest neighbours*, KNN) je neparametarska metoda čiji su izlazi članovi klasa. Objekat se klasifikuje glasovima većine svojih suseda, tako da bude raspoređen u klasu koja je najčešća kod k najbližih suseda. Pod najbližim susedima se misli na podatke iz trening skupa koji imaju najviši stepen sličnosti vektora atributa sa posmatranim vektorom atributa.

Metoda nosećih vektora (eng. *Support Vector Machine*, SVM) predstavlja jedan od moćnijih modela za klasifikaciju. To je u osnovi binarni neprobabilistički klasifikator, što znači da je izlaz modela samo klasifikaciona odluka, i to najčešće 0 i 1, ili +1 i -1. Ova metoda spada u diskriminativne modele pošto modeluje granicu između klasa. Pri klasifikaciji podataka potrebno je pronaći hiper-ravan koja razdvaja podatke koji pripadaju različitim klasama. Hiper-ravan se bira tako da postoji najveća margina između hiper-ravni i bilo koje tačke trening skupa. Noseći vektori su elementi iz skupa podataka koji su najbliži hiper-ravni i da se uklone to bi alterovalo poziciju hiper-ravni, stoga se smatraju krucijalnim elementima u setu podataka.

U narednom poglavlju predstavljeni su rezultati klasifikacije.

### 3 REZULTATI

Za treniranje klasifikatora izdvojeno je 70 %, a za testiranje 30 % podataka iz početnog seta. Rezultati klasifikacije prikazani su kroz tačnost klasifikacije i matrica konfuzije.

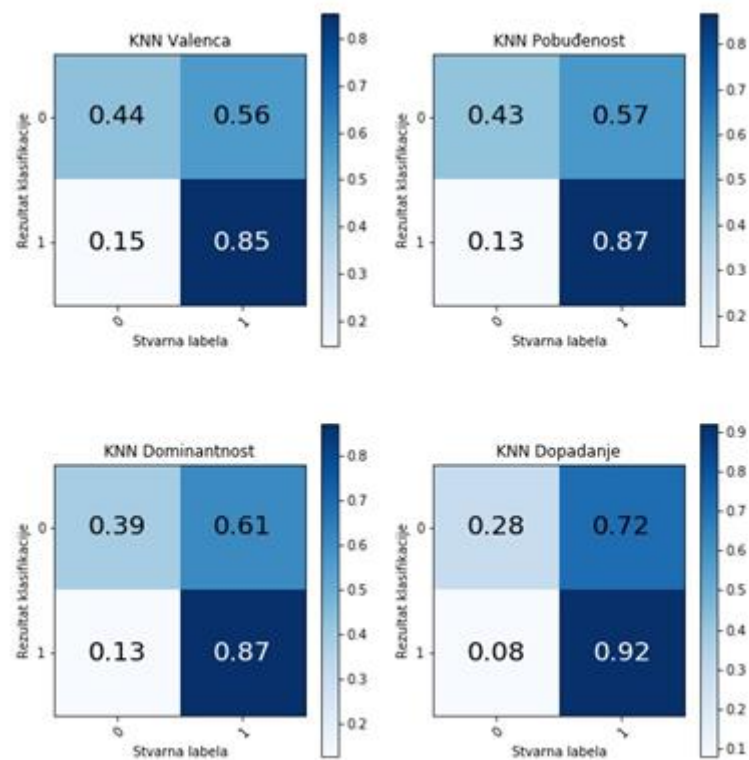
Tačnost klasifikacije (eng. *accuracy*) je mera koja predstavlja odnos ukupnog broja korektnih predviđanja i ukupnog broja predviđanja, to jest ukupnog broja vektora atributa.

Matrica konfuzije (eng. *confusion matrix*) prikazuje uporedni odnos između broja predviđenih i pravih klasa za skup vektora atributa. Redovi matrice odgovaraju pravim vrednostima klasa vektora atributa, dok kolone predstavljaju klase dodeljene od strane modela. Elementi matrice koji se nalaze na glavnoj dijagonali prikazuju korektna predviđanja klasifikacionog modela.

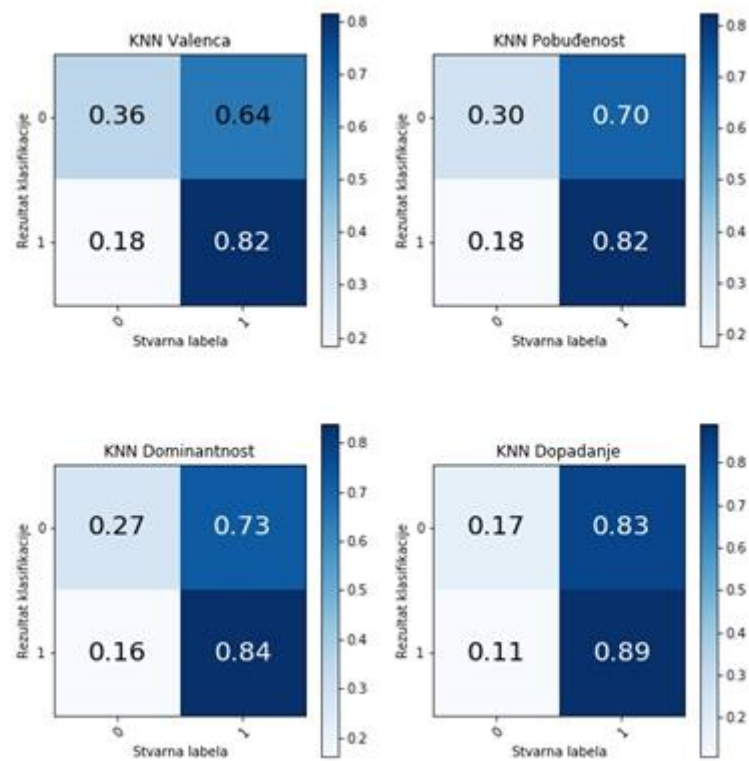
U tabeli 1 prikazane su tačnosti klasifikatora K najbližih suseda nad trenirajućim i testirajućim skupovima. Na slici 6 date su matrice konfuzije za svaki emocionalni doživljaj nad trenirajućim, a na slici 7 nad testirajućim podacima.

*Tabela 2 Tačnost KNN klasifikatora nad trening skupom i nad test skupom*

Emocionalno stanje	Tačnost - trening	Tačnost - test
Valenca	69.98 %	65.10 %
Pobuđenost	70.87 %	63.02 %
Dominantnost	70.53 %	66.66 %
Dopadanje	73.10 %	65.62 %



Slika 6 Konfuzione matrice za trenirajući skup KNN klasifikacije

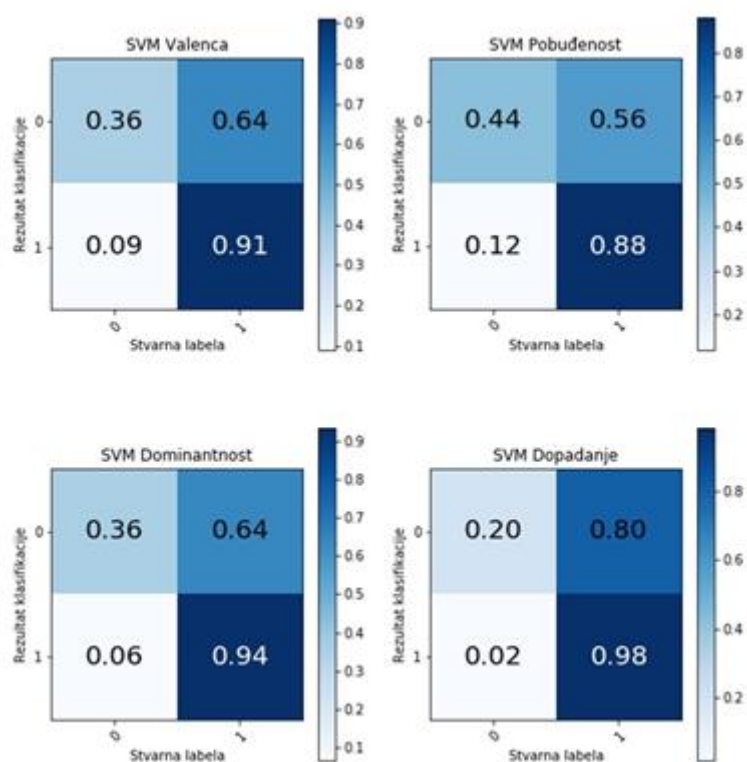


Slika 7 Konfuzione matrice za testirajući skup KNN klasifikacije

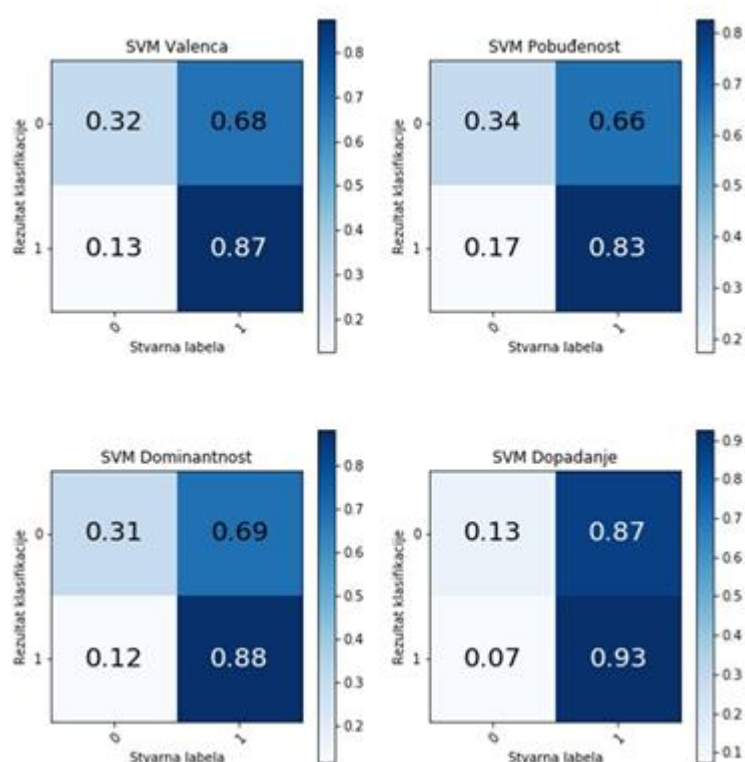
U tabeli 2 prikazane su tačnosti za klasifikaciju metodom nosećih vektora. Na slikama 8 i 9 date su matrice konfuzije za SVM klasifikaciju.

Tabela 3 Tačnost SVM klasifikacije nad trening skupom i nad test skupom

Emocionalno stanje	Tačnost - trening	Tačnost - test
Valenca	70.76 %	67.19 %
Pobuđenost	72.32 %	64.58 %
Dominantnost	73.55 %	70.83 %
Dopadanje	75.22 %	66.41 %



Slika 8 Konfuzione matrice za trenirajući skup SVM klasifikacije



Slika 9 Konfuzione matrice za testirajući skup SVM klasifikacije


Iz ovih rezultata se primećuje da je postizanje tačnosti bolje u slučaju klasifikacije metodom nosećih vektora, ali nijedan model ne uspeva da prepozna nultu klasu nad datim podacima.

U radu [11] iz jula 2018. godine ukazano je da specifično za prepoznavanje emocija nije neophodno koristiti 32 EEG kanala. Predložena je određena lista od 14 kanala: FP1-FP2, F3-F4, F7-F8, FC5-FC6, FC1-FC2, AF3-AF4, C3-C4. Ovi signali su mapirani na osnovu tačnog redosleda kanala koji je dat je u opisu podataka na stranici <https://www.eecs.qmul.ac.uk/mmv/datasets/deap/readme.html>. Klasifikacija je ponovljena, i rezultati su dati kroz tabele 3 i 4 i slike 10, 11, 12, 13.


Tabela 4 Tačnost KNN klasifikatora nad trening skupom i nad test skupom za 14 izdvojenih kanala EEG signala

Emocionalno stanje	Tačnost - trening	Tačnost - test
Valenca	69.98 %	62.50 %
Pobuđenost	70.64 %	60.68 %
Dominantnost	70.87 %	65.62 %
Dopadanje	73.66 %	62.24 %





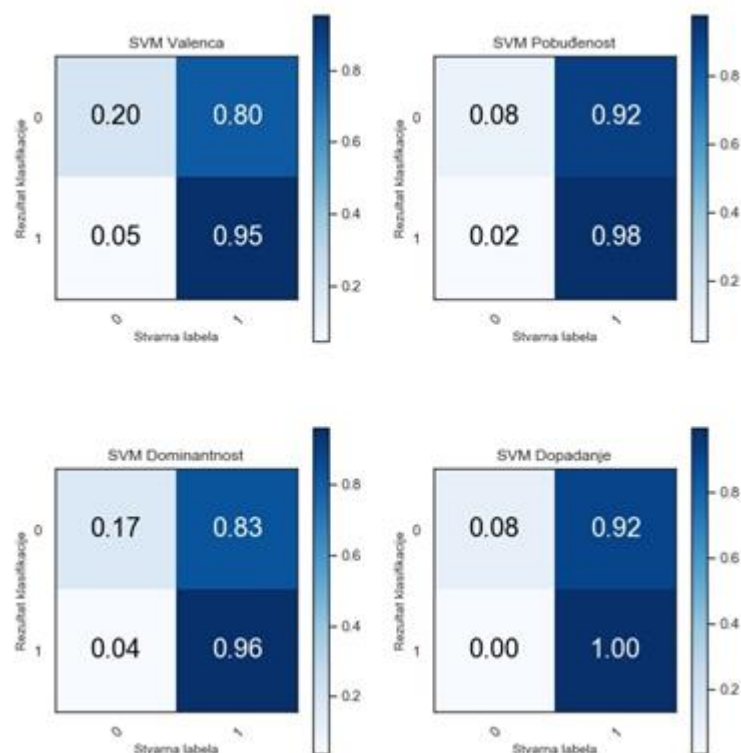
Slika 10 Konfuzione matrice za trenirajući skup KNN klasifikacije za 14 izdvojenih kanala EEG signala



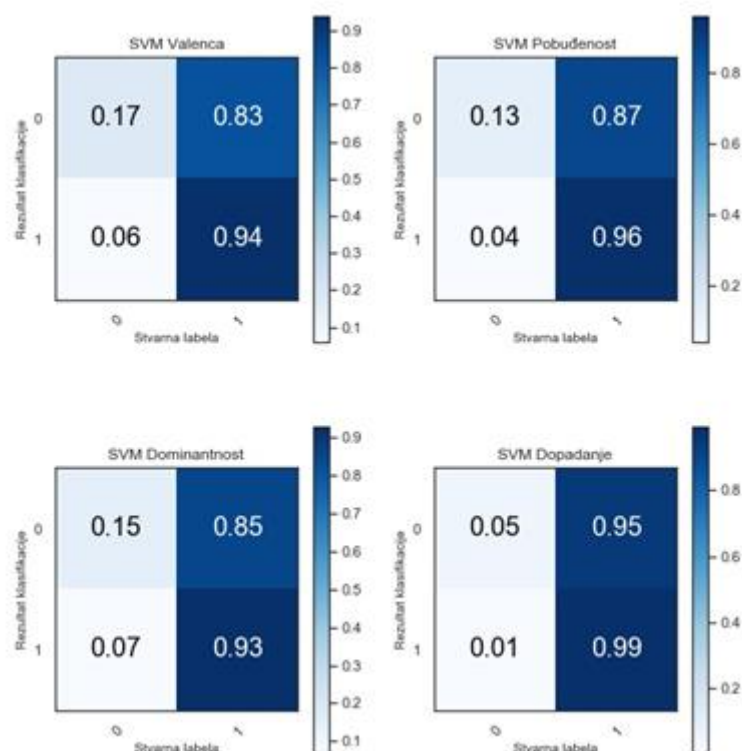
Slika 11 Konfuzione matrice za testirajući skup KNN klasifikacije za 14 izdvojenih kanala EEG signala

Tabela 5 Tačnost SVM klasifikatora nad trening skupom i nad test skupom za 14 izdvojenih kanala EEG signala

Emocionalno stanje	Tačnost - trening	Tačnost - test
Valenca	67.30 %	66.15 %
Pobuđenost	65.51 %	65.10 %
Dominantnost	68.75 %	69.01 %
Dopadanje	72.66 %	68.23 %



Slika 12 Konfuzione matrice za trenirajući skup SVM klasifikacije za 14 izdvojenih kanala EEG signala



Slika 13 Konfuzione matrice za testirajući skup SVM klasifikacije za 14 izdvojenih kanala EEG signala

U slučaju klasifikacije KNN metodom, na osnovu prikazanih rezultata, jasno je da za prepoznavanje emocija nije potrebno analizirati sve kanale EEG signala. Dodatnim izmenama parametara modela, njihovim prilagođavanjem novom, redukovanom skupu obeležja mogla bi se postići adekvatna uspešnost klasifikacije nad obe klase.

Sa SVM klasifikacijom je situacija nešto složenija. Ako se SVM modelu prosledi redukovani skup obeležja, klasifikator teži da prepoznaje samo jednu klasu. U poređenju sa rezultatima nad potpunim skupom obeležja, prepoznavanje nutle klase postaje još manje uspešno.

## 4 DISKUSIJA

Analiza u ovom radu je podeljena na dva dela na osnovu broja ulaznih obeležja. U prvom delu je razmatrana klasifikacija na osnovu izdvojenih obeležja za ukupno 32 kanala EEG merenja. Klasifikacija metodom KNN dostiže najveću tačnost za dominantnost kao emocionalni doživljaj, i to 66,66 %. Metodom nosećih vektora se postiže tačnost od 70,83 % za isto emocionalno stanje. U drugom delu analize razmotrena je mogućnost klasifikacije sa redukovanim brojem ulaznih obeležja. Iz prethodnog skupa izdvojena su obeležja za određenih 14 kanala EEG snimanja, kako je opisano u radu [11]. Ponovo se dobija najveća tačnost za dominantnost, u ovom slučaju KNN metodom se postiže 65,62 %, a SVM klasifikator daje tačnost od 69,01 %. Najbolja prosečna tačnost za klasifikaciju emocija iznosi 67,25 % i postignuta je pomoću metode nosećih vektora nam potpunim skupom obeležja koji podrazumeva sve kanale EEG merenja.

U literaturi [12] se može pronaći uspešnost do 70 % za iste ili slične početne skupove podataka.

Istraživači Wei-Long Zheng, Jia-Yi Zhu i Bao-Liang Lu su 2016.godine u svom radu [4] predstavili model graf regularizovanog ekstremnog brzog treniranja (eng. Graph regularized Extreme Learning Machines, GELM). Njihov pristup se bazirao na praćenju promena emocionalnih stanja kod ispitanika na osnovu EEG signala. Vršena je obrada DEAP baze podataka. Postignuta je najbolja prosečna uspešnost od 69,67 %.

Postavljena očekivanja na početku rada su ispunjena. Postignuta je tačnost interpesonalne klasifikacije emocija koja ne odstupa od drugih, ranijih istraživanja.

## 5 ZAKLJUČAK

U ovom radu implementirano je jedno rešenje za interpersonalnu klasifikaciju emocionalnih doživljaja od mnogih drugih rešenja opisanih u uvodu rada. Zaključuje se da klasifikacija metodom nosećih vektora daje blago bolje rezultate u odnosu na klasifikaciju metodom K najbližih suseda. Obe testirane metode daje lošu statistiku za prepoznavanje nulte klase labeliranih referenci.

Odvajanje klasa bi se bolje postiglo uz nekoliko drugih obeležja, koja bi na primer mogla biti delovi EEG signala u vremenskom domenu, kao i uz obeležja dodatnih fizioloških signala kao što je galvanski odziv kože, GSR (eng. *galvanic skin response*).

Prilikom prikupljanja podataka kao što je baza korišćena u ovom radu, javlja se problem nesigurnosti tačnosti referenci. Ispitanici koji učestvuju u eksperimentima bi trebalo da budu dovoljno samosvesni da znaju da pravilno ocene kako se osećaju kad su izloženi različitim stimulusima.

Nedostaci i problemi na koje se nailazi prilikom rešavanja postavljenog zadatka usko su vezani za varijabilnost i unutrašnju koleralciju ličnih doživljaja kod ljudi, čak i u ovom slučaju kad su rađene analize nad podacima koji nisu pod uticajem voljne kontrole čoveka. To bi se moglo popraviti povećavanjem baze podataka, snimanjem tako da svaki ispitanik bude izložen istom sadržaju nekoliko puta, s ciljem da se postigne bolja normalizacija ulaznih podataka za klasifikatore.

Povećavanje broja ispitanika bi omogućilo bolji uvid u raznolikost elektrofizioloških promena u populaciji. Potencijalno bi mogla da se izvrši kategorizacija ljudi sa sličnim načinom ispoljavanja emocija. Nad ovakvim grupama bi se mogla vršiti kvalitetnija interpersonalna klasifikacija.

## 6 LITERATURA

- [1] Husam K. Salih, Lalit Kulkarni, Study of video based facial expression and emotions recognition methods, 2017. International Conference on I-SMAC (IoT in Social, Mobile, Analytics and Cloud) (I-SMAC) (2017): 692-696.
- [2] Anagha Sonawane, M.Inamdar, Sound based human emotion recognition using MFCC & multiple SVM, 2017 International Conference on Information, Communication, Instrumentation and Control (ICICIC) (2017): 1-4.
- [3] Jonghwa Kim, Elisabeth André, Emotion recognition based on physiological changes in music listening, IEEE Transactions on Pattern Analysis and Machine Intelligence 30 (2008): 2067-2083.
- [4] W. Zheng, J. Zhu and B. Lu, Identifying Stable Patterns over Time for Emotion Recognition from EEG, in IEEE Transactions on Affective Computing, 2016.
- [5] Raja Majid Mehmood, Hyo Jong Lee, EEG based Emotion Recognition from Human Brain using Hjorth Parameters and SVM, BSBT 2015, 2015.
- [6] S. Koelstra, C. Muehl, M. Soleymani, J.-S. Lee, A. Yazdani, T. Ebrahimi, T. Pun, A. Nijholt, I. Patras, IEEE Transaction on Affective Computing, Special Issue on Naturalistic Affect Resources for System Building and Evaluation, u časopisu.
- [7] Dejan Popović, Mirjana Popović, Milica Janković, Biomedicinska merenja i instrumentacija, Univerzitet u Beogradu, Elektrotehnički fakultet, 2009.
- [8] [https://sr.wikipedia.org/wiki/Digitalna\\_obrada\\_signala#Frekventni\\_domen](https://sr.wikipedia.org/wiki/Digitalna_obrada_signala#Frekventni_domen), pristupljeno septembra 2019.
- [9] Plass-Oude Bos, Danny, EEG-based Emotion Recognition. The Influence of Visual and Auditory Stimuli, 2007.
- [10] Boris Milićević, Prepoznavanje emocija na osnovu klasifikacije obeležja fizioloških signala, master rad, Univerzitet u Beogradu, Elektrotehnički fakultet, 2018.
- [11] Li M, Xu H, Liu X, Lu S, Emotion recognition from multichannel EEG signals using K-nearest neighbor classification, Technol Health Care, 2018.
- [12] Lin Shu, Jinyan Xie, Mingyue Yang, Ziyi Li, Zhenqi Li, Dan Liao, Xiangmin Xu, Xinyi Yang, A Review of Emotion Recognition Using Physiological Signals, South China University of Technology, School of Electronic and Information Engineering, 2018.